

可視化事始め

～そのフィギュア、必要ですか？～


2021/3/5 @Keio University

新美 望





Take home message

- ・ まず、最初に何を見せたいのかを3つから考える
 - **分布、関係、差・比率**
 - 差・比率を魅せる時は極力長さで表す（面積は使わない）
- ・ それを実現する為に最もシンプルな図（**データ・インク比率**が良いもの）を実現する
 - Nや分布にも配慮を、連続値に棒グラフは×
- ・ 色盲の人にも分かりやすい色を！

What is this ?



Anscombe's Quartet



統計量	値
x の平均	9 (正確に一致)
x の標本分散	11 (正確に一致)
y の平均	7.50 (小数第2位まで一致)
y の標本分散	4.122 or 4.127 (小数第3位まで一致)
x と y の相関係数	0.816 (小数第3位まで一致)
回帰直線	$y = 3.00 + 0.500x$ (それぞれ小数第2位、小数第3位まで一致)

Visualization

- Tableと異なり、Figureにすることで情報量は格段に上がる！
- 一方で、適切なFigureを描かないと見にくいばかりか、Misleadingにもなりうる
- 内科の問診のように、基礎中の基礎だけど重要極まりない工程

→Visualizationって誰かに習ったっけ？

今日の内容

1. Visualization～良いFigureの条件～
2. データ・インク比
3. 見せたいものと人間の得意分野
4. Nへの意識
5. 3次元プロットって？
6. Tips ～ Gestalteと色使いについて

今日の内容

1. Visualization～良いFigureの条件～

2. データ・インク比

3. 見せたいものと人間の得意分野

4. Nへの意識

5. 3次元プロットって？

6. Tips ～ Gestalteと色使いについて


よいFigureの条件



優れたFigureとはよくデザインされた興味深いデータ--データそのものや統計、そしてデザインの問題--です。透明性・精確性・効率性が複雑に絡み合っています。最も少ないインク・スペースを用いて見たものに即座にいくつもの素晴らしいアイデアを示すことが可能です(Tufte, 1983, p. 51).

Edward Tufte

非常に良いFigureの見本




???

よいFigureの条件



優れたFigureとはよくデザインされた興味深いデータ～データそのものや統計、そしてデザインの問題～です。透明性・精確性・効率性が複雑に絡み合っています。**最も少ないインク・スペースを用いて見たものに即座にいくつもの素晴らしいアイデアを示すことが可能です**(Tufte, 1983, p. 51).

Edward Tufte



データ・インク比を最大化する

今日の内容

1. Visualization～良いFigureの条件～

2. データ・インク比

3. 見せたいものと人間の得意分野



4. Nへの意識

5. 3次元プロットって？

6. Tips ～ Gestalteと色使いについて

インク・データ比の法則


- そのプロットの中で意味がある部分と使ったインクの割合を小さくすることが良いプロットの特徴
→簡単にいうと「シンプルイズベスト」



今日の内容

1. Visualization～良いFigureの条件～
2. データ・インク比
3. 見せたいものと人間の得意分野
4. Nへの意識
5. 3次元プロットって？
6. Tips ～ Gestalteと色使いについて
7. Take home message


見せたいものって？



見せたいものは
大体この3種類に大別

この6種類が基本のキ

人間の得意(苦手?)分野




Example




どちらが分かりやすいですか？

青が感染症
赤が戦場での負傷
黒がその他



Annual rate of mortality per 1000





今日の内容



1. Visualization～良いFigureの条件～
2. データ・インク比
3. 見せたいものと人間の得意分野
4. **Nへの意識**
5. 3次元プロットって？
6. Tips ～ Gestalteと色使いについて

Nへの意識

- 連続値の平均や中央値を比較する時には分布も非常に重要！
 - 分布を見る時にはバイオリンプロットもよし
- サンプルサイズの大きさに、使う図表を分けるべき
- 一つの目安として $n < 30$ ではドットチャートを併用する




What's this ?




???

What's this ?

STEMI患者のPCI後のCKの値の平均





STEMI患者のPCI後のCKの値の中央値



???

???

That's it!!




!!!!

Nへの意識

何かの比較の時には必ず分布も考慮する


→箱ひげ図やバイオリンプロットは非常に見やすい

一方で、Nが小さいときにはその意味も変わるので、Nが少ないときはそのデータも入れた方が良い






Nへの意識と見やすさの両立

ドットチャートに要約(平均・中央値)を追加した上で、ドットを出来るだけ薄くする



まとめ

Figure Types	Example	Type of Variable	What the Plot Shows	Sample Size	Data Distribution	Best Practices
Dot plot		Continuous	Individual data points & mean or median line Other summary statistics (i.e. error bars) can be added for larger samples	Very small OR small; can also be useful with medium samples	Sample size is too small to determine data distribution OR Any data distribution	- Make all data points visible - use symmetric jittering - Many groups: Increase white space between groups, emphasize summary statistics & de-emphasize points - Only add error bars if the sample size is large enough to avoid creating a false sense of certainty - Avoid "histograms with dots"
Dot plot with box plot or violin plot		Continuous	Combination of dot plot & box plot or violin plot (see descriptions above and below)	Medium	Any	- Make all data points visible (symmetric jittering) - Smaller n: Emphasize data points and de-emphasize box plot, delete box plot and show only median line for groups with very small n - Larger n: Emphasize box plot and de-emphasize points
Box plot		Continuous	Horizontal lines on box: 75 th , 50 th (median) and 25 th percentile Whiskers: varies; often most extreme data points that are not outliers Dots above or below whiskers: outliers	Large	Do not use for bimodal data	- List sample size below group name on x-axis - Specify what whiskers represent in legend
Violin plot		Continuous	Gives an estimated outline of the data distribution. The precision of the outline increases with increasing sample size.	Large	Any	- List sample size below group name on x-axis - The violin plot should not include biologically impossible values
Bar graph		Counts or proportions	Bar height shows the value of the count or proportion	Any	Any	Do not use for continuous data


今日の内容

1. Visualization～良いFigureの条件～
2. データ・インク比
3. 見せたいものと人間の得意分野
4. Nへの意識
5. 3次元プロットって？
6. Tips ～ Gestalteと色使いについて



3次元プロットって？

- 基本的にはMisleading
- 使わなくて済むなら絶対に使わない
- 一番ダメなのが3次元円グラフ

青と紫どちらが大きいですか？



どちらが見やすい？



今日の内容

1. Visualization～良いFigureの条件～
2. データ・インク比
3. 見せたいものと人間の得意分野
4. Nへの意識
5. 3次元プロットって？
6. **Tips ～ ゲシュタルトと色使いについて**

ゲシュタルトとは





Figure 1.21: Gestalt inferences: Proximity, Similarity, Connection, Common Fate. The layout of the figure employs some of these principles, in addition to displaying them

近接の法則
類同の法則
囲みの法則
閉合の法則
連続の法則
接合の法則

推奨はしないけど




色使いについて


色覚異常は思っている以上にコモン カラーユニバーサルデザイン

■ 主な色覚異常の種類

種類	解説
1型色覚 (Protanopia)	赤系統色の識別に困難がある
2型色覚 (Deuteranopia)	緑系統色の識別に困難がある
3型色覚 (Tritanopia)	青色系統の識別に困難がある



カラーユニバーサルデザイン



【P型色覚、D型色覚の方が特に区別の困難な色の組合せ】

- 具体的な色彩の選び方は以下を参照

<https://www.fukushihoken.metro.tokyo.lg.jp/kiban/machizukuri/kanren/color.files/colorudguideline.pdf>

Data Visualization Guidelines

Figures representing data need to be designed and presented in a way that allows readers to understand and critically interpret the data. In general, authors are expected to adhere to the following guidelines:

- Bar graphs should be avoided except when showing counts or proportions. Continuous data and small sample sizes should be represented with figures that show the full data distribution, such as dot or scatter plots.
- When possible, all data points should be made visible in figures. Consider using semi-transparency or show gradients in scatter plots and flow-cytometry figures and symmetric jittering in dot plots.
- Consider adding a flow chart or study design diagram when appropriate. Flow charts should provide information about the number of excluded observations and reasons for exclusion at each phase of the study.
- Ensure that figures use easily distinguishable colors/lines/symbols and are colorblind-safe. Free resources, such as [Color Oracle](#), are available to test figure colors.

For additional guidelines, information, and resources, please see the following Primer article published in *Circulation*: [Reveal, Don't Conceal: Transforming Data Visualization to Improve Transparency](#)

Take home message

- ・ まず、最初に何を見せたいのかを3つから考える
 - **分布、関係、差・比率**
 - 差・比率をみせる時は極力長さで表す（面積は使わない）
- ・ それを実現する為に最もシンプルな図（データ・インク比率が良いもの）を実現する
 - Nや分布にも配慮を、連続値に棒グラフは×
- ・ 色盲の人にも分かりやすい色を！

Reference

- *Reveal, Don't Conceal: Transforming Data Visualization to Improve Transparency.* *Circulation.* 2019;140(18):1506-1518.
- *Graphics and statistics for cardiology: Comparing categorical and continuous variables.* *Heart.* 2016;102(5):349-355.
- 永田ゆかり(2020)『データ視覚化のデザイン』SBクリエイティブ株式会社
- キーラン・ヒーリー(2021)『実践Data Scienceシリーズ データ分析のためのデータ可視化入門』KS情報科学専門書
- https://moderndive.github.io/moderndive_labs/static/previous_versions/v0.5.0/3-viz.html
- <https://socviz.co/lookatdata.html>
- https://seaborn.pydata.org/tutorial/function_overview.html

- ご静聴ありがとうございました

Chart Suggestions—A Thought-Starter

