

分類モデルの評価について

2021/7/30

Nozomi Niimi

- “そのしるされた文字はこうです。メネ、メネ、テケル、ウパルシン。その事の解き明かしはこうです、メネは神があなたの治世を数えて、これをその終りに至らせたことをいうのです。
テケルは、あなたがはかりで量られて、その量の足りないことがあらわれたことをいうのです。
ウパルシンは、あなたの国が分かれたれて、メデアとペルシャの人々に与えられることをいうのです。”

ダニエル書第五章

Take home message

- 分類モデルの場合は**弁別能**と**較正能**を別個に評価しよう！
 - ✓ 弁別能：AUROC
 - ✓ 較正能：Calibration plotを用いる
 - 分類モデルの場合はクラスの偏りに要注意！
- モデルの比較にNRI, **Decision-curve analysis**も使おう！

Agenda

- 分類モデルとは？
- 分類の評価 ～ DiscriminationとCalibrationって何？
 - ✓ Discriminationの評価方法
 - ✓ Calibrationの評価方法
- Advanced model performance～モデルの比較～
 - ✓ NRI、IDI、Decision curve analysis

Agenda

- **分類モデルとは？**
- 分類の評価 ～ DiscriminationとCalibrationって何？
 - ✓ Discriminationの評価方法
 - ✓ Calibrationの評価方法
- Advanced model performance～モデルの比較～
 - ✓ NRI、IDI、Decision curve analysis

分類モデルとは？

- いわゆるモデルは大きく分けて回帰モデルと分類モデルに分けられる
 - ✓回帰モデル：連続値(BNP値、e'、PCWPなど)を直接予測する
 - ✓分類モデル：0/1(生死、出血の有無など)を予測する
- 実際の分類モデルは0.4, 0.357などイベントが起きる確率を計算され、任意のカットオフ(通常0.5)で0か1に丸め込んでいる

truth	predicted
5.1	5.004788
4.9	4.756844
4.7	4.773097
4.6	4.889357
5.0	5.054377
5.4	5.388886

連続値

prob_Class1	predicted	truth
0.003589243	Class2	Class2
0.678621054	Class1	Class1
0.110893522	Class2	Class2
0.735161703	Class1	Class1
0.016239960	Class2	Class2
0.999275071	Class1	Class1

分類

Agenda

- 分類モデルとは？
- **分類の評価 ～ DiscriminationとCalibrationって何？**
 - ✓ Discriminationの評価方法
 - ✓ Calibrationの評価方法
- Advanced model performance～モデルの比較～
 - ✓ NRI、IDI、Decision curve analysis

分類の評価 ~ DiscriminationとCalibration

- 分類モデルの評価には
Discrimination(弁別能)と**Calibration(較正能)**の
両者を別個に評価する
 - ✓ **Discrimination**は0/1の正確性、実際にこの患者の予測が当たるかどうかの評価
 - ✓ **Calibration**はその患者のリスクの絶対値の評価。
 - まずはDiscrimination > Calibrationだが、特に実臨床ではCalibrationも重要な評価項目
- Calibrationはしばしば忘れ去られている

例


- **Discrimination :**

- ✓ 「ERで胸痛を訴えているこの患者がMIかどうか？」
→そもそも、これが当たらないとどうしようもない

- **Calibration :**



- ✓ 「この患者にPCIをしたときに透析になってしまう確率は？」
→20%を超えるようならカテなしで様子を見よう
→0/1だけでなく、実際の数字が重要

DiscriminationとCalibration



完璧なDiscrimination
& poor calibration

- DiscriminationとCalibrationはトレードオフ
- さらに、事前確率やその分布にも影響を受ける




完璧なCalibrationでの理論
上の最大のDiscrimination

Discriminationの評価について

- 0/1の評価(混合行列からの計算)
 - ✓ **Accuracy**、感度、特異度、 $F\beta$ scoreなど
- リスク毎の感度・特異度などを評価したもの
 - ✓ **ROC**、PR curve

truth	prob of Class1	predicted
Class2	0.003589243	Class2
Class1	0.678621054	Class1
Class2	0.110893522	Class2
Class1	0.735161703	Class1
Class2	0.016239960	Class2
Class1	0.999275071	Class1



Truth		
Prediction	Class1	Class2
Class1	227	50
Class2	31	192

Discrimination～混合行列

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

カットオフを
作るのにも使う



$$F_{\beta} = \frac{(1 + \beta^2) \cdot \text{true positive}}{(1 + \beta^2) \cdot \text{true positive} + \beta^2 \cdot \text{false negative} + \text{false positive}}$$

実際の
クラス


予測されたクラス			
		P	N
P	実際の クラス	真陽性 (TP)	偽陰性 (FN)
		偽陽性 (FP)	真陰性 (TN)

- 国試でやった感度・特異度・尤度比等
- 一番使われるのは**Accuracy**
- F_{β} score(F1, F0.5, F2など)で偽陰性・偽陽性の何を重視するかで選択が変わる。
 - ✓ β に大きな数字を入れると感度を重視し、小さな数字を入れるとPPVを重視する
 - 偽陰性を極力避けたいとき(一般人口への癌やHIVのScreening)はF2等が良い
 - 偽陽性を極力避けたいとき(HFrEFで心筋生検をすべきかどうか)はF0.5等が良い

リスク毎の評価



prob_Class1	truth
0.003589243	Class2
0.678621054	Class1
0.110893522	Class2
0.735161703	Class1
0.016239960	Class2
0.999275071	Class1



threshold	recall	precision	specificity	sensitivity
<db 1>	<db 1>	<db 1>	<db 1>	<db 1>
Inf	0	1	1	0
1.00	0.00388	1	1	0.00388
1.00	0.00775	1	1	0.00775
1.00	0.0116	1	1	0.0116
1.00	0.0155	1	1	0.0155
1.00	0.0194	1	1	0.0194
1.00	0.0233	1	1	0.0233
1.00	0.0271	1	1	0.0271
1.00	0.0310	1	1	0.0310
1.00	0.0349	1	1	0.0349

注意点

AUROCの値	意味
0.5-0.6	poor
0.6-0.75	possible helpful
0.75-	Clearly useful

JAMA. 2017 Oct 10;318(14):1377-84.

- 極端に偏ったデータでは混合行列関連は役に立たない
→特に**Accuracy**が一番ダメ(全部0の予測でも90%超えてしまう)
- **PRAUC**等が役に立つが数字だけでの評価は困難
 - ✓ ROCは事前確率に関係のない感度・特異度だけでできているが、PR curveは事前確率が影響する
 - PR curveはより不均衡なデータでモデルの差をちゃんと見つけやすい (ROCだと差が出にくい)
- **AUROC**は数字で大体の印象が分かるのが強み



結局どうすればいいの？

- 均衡がとれているデータの場合
 - ✓何かしら根拠がある(妥当な感度、特異度の値が分かっている)
 - カットオフをこちらで決めてAccuracy、感度/特異度やF1 valueを記載
 - AUROCはあった方が良い
 - ✓根拠がない場合
 - Youden indexや $F\beta$ scoreをカットオフとしてAccuracy等評価
 - AUROCは必須
- 不均衡データの場合：あまり決まっていない
 - ✓AUPRCは何処かに記載した方が無難、個人的には不均衡でもAUROCをメイン解析にしても良いと思う
 - ✓Youden indexや $F\beta$ scoreなどを用いて、意味があるカットオフを作ってからNNT等評価する

Calibrationの評価について

- 全体像を示すもの
 - ✓ Calibration plot
- 一つの数字で表すもの
 - ✓ Recalibration parameters : Calibration plotの傾きと切片を記述
 - ✓ Hosmer-Lemeshow : 予測確率からn個の群分けを行って、その中で期待される発生件数と実際の発生件数を χ^2 検定を行う
 - ✓ Brier score : 実際のイベントと予測確率の差を二乗和にして平均を取った値

→ **Calibration plot** がどこの予測能が悪いかもわかるため、最も良い評価(分類数には要注意)！



①

truth	Prob of Class1	predicted	rank
Class2	0.003589243	Class2	1
Class1	0.678621054	Class1	3
Class2	0.110893522	Class2	2
Class1	0.735161703	Class1	3
Class2	0.016239960	Class2	1
Class1	0.999275071	Class1	5



② ③ ④ ③' ④'

rank	mean_prob	mean_inc	n	incidence
<int>	<dbl>	<dbl>	<int>	<int>
1	0.00642	0.01	100	1
2	0.145	0.2	100	20
3	0.630	0.47	100	47
4	0.946	0.92	100	92
5	0.997	0.98	100	98

Agenda

- 分類モデルとは？
- 分類の評価 ～ DiscriminationとCalibrationって何？
 - ✓ Discriminationの評価方法
 - ✓ Calibrationの評価方法
- **Advanced model performance～モデルの比較～**
 - ✓ NRI、IDI、 Decision curve analysis

モデルの比較

- AU-ROCでは有用なマーカーを追加しても元のモデルの性能によっては追加による性能の改善を捉えられない事が知られている





→シチュエーションとして多いのは、ベースのモデルに何かの変数を追加したときにモデルが良くなるかどうか？

✓NRI/IDI

AUROCは不完全！

TABLE 1. Contributions to Cardiovascular Disease Prediction in the Women's Health Study*

Variable	Variable χ^2	P	RR per 2 SD†	c Statistic
Effect of adding variables to model with age only				
Ln(age) only	395.9	<0.0001	4.0	0.70
+Ln(SBP)	148.8	<0.0001	2.5	0.74
+Current smoking†	121.1	<0.0001	2.9	0.73
+Ln(HDL)	85.7	<0.0001	1/2.0	0.73
+Ln(TC)	33.3	<0.0001	1.6	0.72
+LDL	28.8	<0.0001	1.5	0.71



NRI(Net reclassification index)

- 古いモデル→新しいモデルでの分類によってどのように変化したかを示す
- 実は複数の種類がある
- 大きく分けて

✓ **Category-based NRI**

✓ **Continuous NRI**

に分けられる

A Example 1

① Patients with events (n=10 000, 50% of total)

③ NEW MODEL

	Low risk	Moderate risk	High risk	Totals, old model
② OLD MODEL Low risk	2500	④ 2200 ^{a+}	400 ^{b+}	4100
Moderate risk	⑤ 300 ^{d+}	2500	600 ^{c+}	3400
High risk	50 ^{e+}	350 ^{f+}	2100	2500
Totals, new model	2850	4050	3100	10000

① Patients without events (n=10 000, 50% of total)

③ NEW MODEL

	Low risk	Moderate risk	High risk	Totals, old model
② OLD MODEL Low risk	4000	⑤' 300 ^{a-}	100 ^{b-}	4400
Moderate risk	④' 100 ^{d-}	4000	150 ^{c-}	4250
High risk	50 ^{e-}	100 ^{f-}	1200	1350
Totals, new model	4150	4400	1450	10000

	Patients with events, No.		Patients without events, No.		
Correct reclassification	2200	④	250	④'	Additive NRI 12
Incorrect reclassification	700	⑤	550	⑤'	Absolute NRI 6%
Net reclassification	1500	④-⑤=⑥	-300	④'-⑤'=⑥'	

cNRI

- Continuous NRI：全てのカットオフでのNRIの平均

→ $\text{Pr}(\text{higher}|\text{event}) - \text{Pr}(\text{lower}|\text{event}) + \text{Pr}(\text{lower}|\text{nonevent}) - \text{Pr}(\text{higher}|\text{nonevent})$
の方が分かりやすい

✓ 恣意的ではなくなるメリット


✓ 元のAUROCに関連なく改善度合いが分かる → 新規に加えたマーカの影響を評価可能

✓ 弱いマーカでもポジティブになりやすく、Miscalibrationの影響を強く受ける

✓ イベントの大小関係しか見ない為、意味がない差も拾ってしまう

→ Old modelの予測確率が0.98に対してNew modelの予測確率が0.99でも改善とみなしてしまう

truth	model_old	model_new
1	0.7902078	0.9981555
1	0.7902078	0.9984236
1	0.7565653	0.9513752
0	0.7565653	0.9414274
1	0.7837628	0.9677432
1	0.7837628	0.9712299



truth	n	`new > old`	`old > new`
<dbl>	<int>	<int>	<int>
0	18	3	15
1	58	46	12

$$(15-3)/18 + (46-12)/58 = 1.25$$


NRIの使い方、注意点

- **Event NRI、Non-event NRIの各々を提示する**
 - ✓可能であれば、臨床的に意味があるカットオフでの**Category-based NRI**が望ましい
- NRI単独で評価はせず、補助的に用いる(AUROC等と一緒に)
 - Calibrationがもともと悪いデータだと意味がなくても有意に改善する可能性がある
- 最も良い使い方は全く関係のないモデルではなく、古いモデルに新たなマーカーを追加した後のモデルの評価

IDI(integrated discrimination improvement)

- cNRIに各々の予測値の重みづけをしたもの
- (Eventあり群の新/旧モデルの平均予測値の差)-(Eventなしにおける新/旧モデルの予測平均値の差)をとったもの
- Calibrationの要素が入っているが、やはり臨床的な差は見つけにくい

status	model_old	model_new
1	0.9135125	0.9981555
1	0.9135125	0.9984236
1	0.7066665	0.9513752
0	0.7066665	0.9414274
1	0.9103698	0.9677432
1	0.9103698	0.9712299



status	n	mean_old	mean_new
<dbl>	<int>	<dbl>	<dbl>
0	18	0.734	0.463
1	58	0.772	0.856

$$(0.856-0.772) - (0.463-0.734) = 0.355$$

Decision curve analysis

- NRI/IDIは偽陽性と偽陰性を同じ重みづけで扱っている
→現実には偽陽性が望ましくない時と偽陰性が望ましくない時がある
Ex)ICUの心電図モニター vs. HFrEFの心臓生検
- 重みづけをした上でのNet benefitを確率毎に記述したグラフを
Decision curveという

$$\text{Net Benefit} = \frac{\text{TruePositiveCount}}{n} - \frac{\text{FalsePositiveCount}}{n} \left(\frac{p_t}{1 - p_t} \right)$$

BMJ 2016;352:i6.

truth	Prob of Class1	predicted_0.5	predicted_0.1
Negative	0.003589243	Negative	Negative
Positive	0.678621054	Positive	Positive
Negative	0.110893522	Negative	Positive
Positive	0.735161703	Positive	Positive
Negative	0.016239960	Negative	Negative
Positive	0.999275071	Positive	Positive

$P(t)=0.1$


Truth		
Prediction	Negative	Positive
Negative	132	6
Positive	110	252

$$\text{NB} = 252/500 - 110/500 * (0.1/0.9) = 0.480$$

$P(t)=0.5$

Truth		
Prediction	Negative	Positive
Negative	192	31
Positive	50	227

$$\text{NB} = 227/500 - 50/500 * (0.5/0.5) = 0.354$$



- Net benefitの値のところでの最も上のStrategyがより良いモデル
- Treat allとTreat noneよりは常に高くないといけない
- 左端のベースラインのリスクの高低も必ず評価する

DCA、NBの解釈

- 高価な検査あるいは侵襲的や面倒な検査の場合、 ΔNB の逆数がNNTと同じような役割を果たす(Test tradeoff)
→心Sarcoidosisの診断にPETを加えたモデルがあったとして、 $P(t)$ が10%の時の ΔNB が0.001の場合、10%以上で陽性をするという基準でNNS 1000(言い換えると111回やると1回の偽陽性を避けられる)

Decision curveの読み方・作り方

- 1. 重要な事は、 $P(t)$ のレンジを現実的な範囲で決める事(下限と上限)
 - **1.1 モデルから逆に $P(t)$ を決めてはいけない！！**
- 2. 有病率($P(t)=0$ の時のNB)の値も確認
- 3. 興味があるレンジでどのような動態かを確認する
 - 3.1 Calibrationが悪いとTreat allやTreat noneよりも悪くなりうる
→その場合はそれ以上の比較はしない
- 4. 新しいモデルの費用や侵襲性、疾患の重要性などを勘案してNBの差を評価する
 - 4.1 必要時、NBの逆数やOddsとの差を取ってtest tradeoffを評価

結局どうすればいいの？

- モデルを単に評価するだけなら不要
- ベースのモデルに対してどの程度変化したかを記述したい、または元に対して何かのマーカー(BNP等)を追加したときにその改善している事を言いたい
 - **cNRI**
- 臨床的な有用性を強く主張したい
 - ある程度適切なカットオフを自分で決めて、Category-based NRIをevent/non-eventで記述する
 - **Decision curve analysis**を用いる

Take home message

- 分類モデルの場合は**弁別能**と**較正能**を別個に評価しよう！
 - ✓ 弁別能：AUROC
 - ✓ 較正能：Calibration plotを用いる
 - 分類モデルの場合はクラスの偏りに要注意！
- モデルの比較にNRI, **Decision-curve analysis**も使おう！

参考文献

- 『イベント予測モデルの評価指標』

https://www.jstage.jst.go.jp/article/jjb/41/1/41_1/pdf

- Net Reclassification Improvement: Computation, Interpretation, and Controversies. Ann Intern Med 2014;160:122–131.
- Net benefit approaches to the evaluation of prediction models, molecular markers, and diagnostic tests. BMJ 2016;352:i6.
- Van Calster B, Wynants L, Verbeek JFM, Verbakel JY, Christodoulou E, Vickers AJ, et al. Reporting and interpreting decision curve analysis: A guide for investigators. Eur Urol 2018;74:796–804.
- Steyerberg EW, Vickers AJ, Cook NR, Gerds T, Gonen M, Obuchowski N, et al. Assessing the performance of prediction models: a framework for traditional and novel measures. Epidemiology 2010;21:128–138.